

Universidad del Valle de Guatemala

Data Science

Ing. Mario Barrientos



Laboratorio IV: Informe de datos geoespaciales

José Donado

Daniela Ramirez

Cindy Gualim

Resumen

Se desarrolló un modelo de aprendizaje automático (Gradient Boosting) para identificar zonas con alta presencia de cianobacteria en los lagos de Atitlán y Amatitlán a partir de imágenes Sentinel-2. El conjunto final incluyó 228,886 observaciones correspondientes a píxeles válidos de agua de 16 escenas confiables. Los resultados mostraron diferencias importantes entre ambos lagos: el 63.9 % de los píxeles de Amatitlán superó el umbral de floración, mientras que en Atitlán solamente lo hizo el 1.4%. Por otra parte, el modelo presentó buen rendimiento para reducir falsos negativos (recall), con 90% para Atitlán y 99% para Amatitlán.

Objetivo y metodología

El objetivo fue construir un modelo capaz de estimar la probabilidad de alta presencia de cianobacteria y producir mapas que permitieran localizar zonas prioritarias para monitoreo. La variable de respuesta se definió usando un umbral de 10 mg/m³ de clorofila-a. Es decir que, si superaba este límite se consideraba a la zona como una de alta presencia de cianobacteria. Cada observación incluyó bandas espectrales, NDVI, NDWI, ubicación geográfica y variables temporales. Para evitar fuga de información se excluyeron la clorofila-a, NDCI, B04 y B05, ya que estas variables determinan directamente la clasificación utilizada como respuesta.

Los datos se dividieron en 70 % para entrenamiento y 30 % para prueba, manteniendo la proporción de clases. Se evaluaron Regresión Logística, Random Forest y Gradient Boosting, utilizando pesos balanceados y ajuste de hiperparámetros. Además de la división aleatoria, se realizó validación espacial mediante bloques de 1 km², validación temporal agrupando las observaciones por fecha y experimentos de generalización entre los dos lagos.

Análisis

En la evaluación convencional, Random Forest obtuvo el mejor F1, con 0.8799, mientras que Gradient Boosting alcanzó el mejor recall, con 0.9589, y el mejor F2, con 0.9043. Gradient Boosting dejó sin detectar 238 píxeles positivos, frente a 489 del Random Forest, aunque produjo una mayor cantidad de falsas alarmas. Debido a que el objetivo ambiental principal es reducir las floraciones no detectadas, Gradient Boosting fue seleccionado como el modelo más apropiado.

La validación espacial produjo una reducción moderada del desempeño: el F1 de Gradient Boosting pasó de aproximadamente 0.84 a 0.82. En cambio, la validación temporal redujo su F1 hasta aproximadamente 0.60, lo cual indica que la división aleatoria sobreestimaba la capacidad de predecir fechas nuevas. La transferencia entre lagos también fue limitada: el modelo obtuvo un F1 de 0.79 al entrenar con Atitlán y evaluar con Amatitlán, pero su desempeño disminuyó considerablemente en la dirección contraria debido a las diferencias de prevalencia, profundidad, turbidez y propiedades ópticas de ambos lagos.

Interpretación de resultados

Los análisis de importancia global y SHAP permitieron identificar las variables espectrales, espaciales y temporales que más influyeron en las predicciones. Los mapas predictivos distinguieron zonas de probabilidad muy baja, baja, alta y muy alta, y permitieron localizar verdaderos positivos, falsos positivos y falsos negativos. Los errores se concentraron especialmente en sectores donde la turbidez, los sedimentos, la vegetación superficial o la mezcla entre agua y orilla pueden generar firmas espectrales similares a una floración. Estas predicciones representan áreas prioritarias para inspección, pero no constituyen una confirmación directa de cianobacterias o toxinas.

Recomendaciones para la gestión ambiental

En Amatitlán, se recomienda priorizar el monitoreo y control de nutrientes y aguas residuales, especialmente en las zonas donde su acumulación es constante. Los mapas pueden utilizarse para identificar puntos críticos y orientar los muestreos de campo hacia las áreas que requieren mayor atención.

En Atitlán, sería conveniente implementar un sistema de alerta temprana para detectar floraciones localizadas cerca de la costa. También se recomienda realizar muestreos de agua al mismo tiempo que pasa el satélite, midiendo clorofila-a, especies de cianobacterias, toxinas, fósforo, nitrógeno, temperatura y transparencia.

El monitoreo debe mantenerse de forma regular durante varios años, procurando una cantidad similar de observaciones en las épocas seca y lluviosa. Además, es importante registrar variables como lluvia, viento, temperatura, descargas y cambios en el uso del suelo para comprender mejor las causas de cada evento.

Para identificar posibles floraciones, el NDCI es el índice más adecuado. El NDWI debe utilizarse principalmente para identificar cuerpos de agua y el NDVI para detectar vegetación o posibles interferencias. Finalmente, las imágenes con nubes, cobertura incompleta o valores extremos deben revisarse manualmente antes de emitir una alerta

Consideración final

El análisis mediante imágenes satelitales es una herramienta útil para la vigilancia, seguimiento y priorización de áreas que pueden presentar proliferaciones de algas o cianobacterias. Sin embargo, este tipo de análisis no sustituye los estudios y muestreos realizados directamente en campo. Las imágenes obtenidas por Sentinel-2 permiten identificar cambios en la respuesta óptica del agua relacionados con la presencia de clorofila-a, lo que ayuda a localizar zonas con mayor actividad algal. Aun así, la información satelital por sí sola no permite determinar con certeza qué especie de cianobacteria está presente, si existe producción de toxinas o si las concentraciones detectadas representan un riesgo para la salud humana o para el ecosistema.

Por otro lado, el modelo desarrollado presenta capacidad útil como herramienta de apoyo para el monitoreo, principalmente para generar alertas preliminares y orientar muestreos de campo. Sin embargo, no debe utilizarse como sistema autónomo porque su desempeño disminuye al evaluar fechas o lagos no observados durante el entrenamiento. Las principales limitaciones fueron la escasa cantidad de fechas, el desbalance entre lagos, la nubosidad, la dependencia espacial y temporal y la ausencia de mediciones físicas. Para mejorar el sistema se recomienda incorporar más años de imágenes, datos meteorológicos e hidrológicos y mediciones de campo de clorofila-a, células de cianobacteria, nutrientes y cianotoxinas.